

Regresión por menor ángulo (LARS)

Intuición detrás de LARS

Notemos que la regresión por pasos tiene la ventaja de que llega a una solución en a lo más $\min\{n, p\}$ pasos, pero como mencionamos antes, como añadimos “mucho” de un predictor en cada iteración, podemos, sin darnos cuenta, eliminar alguno que fuera relevante. El algoritmo de regresión por etapas intenta resolver este problema, pero al costo de introducir muchas iteraciones. El objetivo de el algoritmo de regresión por menor ángulo es obtener los beneficios de ambos realizando decisiones “inteligente” de que predictores añadimos en cada paso y “cuanto” añadimos de cada uno.

Al igual que en los dos algoritmos anteriores, la idea es añadir predictores hasta que estemos satisfechos. Tomemos primero el caso donde

$$X = \begin{bmatrix} x_{1,1} & x_{1,2} \\ x_{2,1} & x_{2,2} \end{bmatrix}.$$

Supongamos que $|\langle x_1, y \rangle| > |\langle x_2, y \rangle|$, de manera que si θ_1 es el ángulo entre x_1, y y θ_2 es el ángulo entre x_2, y , entonces

$$|\cos(\theta_1)| \|y\| = |\langle x_1, y \rangle| > |\langle x_2, y \rangle| = |\cos(\theta_2)| \|y\| \Rightarrow |\cos(\theta_1)| > |\cos(\theta_2)|.$$

Esto nos dice que $|\cos(\theta_1)|$ está más cercano a 1, y por tanto, como $\cos(0) = \cos(\pi) = 1$, se tiene que si consideramos la recta marcada por y , entonces el ángulo formado por x_1 y dicha recta es más pequeño que el formado por x_2 , como se observa en la Figura ??, de modo que damos un paso en esta dirección (considerando el signo que tiene $\langle x_1, y \rangle$). Ahora bien, vamos a dar un tamaño de paso muy especial. Como el algoritmo termina en el siguiente paso y queremos llegar a la solución usual de mínimos cuadrados, consideramos un tamaño de paso $\hat{\gamma}_1$ de manera que si $\hat{y}$ es dicho estimador, entonces $\hat{y} - \hat{\gamma}_1 x_1$ biseque el ángulo entre x_1 y x_2 , esto es que $\hat{y} - \hat{\gamma}_1 x_1$ tenga la misma correlación con x_1 y x_2 , de manera que nuestra estimación actual es $\hat{\gamma}_1 x_1$. Después, continuamos en la dirección marcada por dicha bisectriz, específicamente, si u_2 es el vector unitario que biseca dicho ángulo, entonces nuestra siguiente estimación es $\hat{\gamma}_1 x_1 + \hat{\gamma}_2 u_2$, donde $\hat{\gamma}_2$ es elegido para que la estimación final sea $\hat{y}$.




Figura 1: Representación gráfica de LARS en dos dimensiones con 2 covariables.

Notemos que el algoritmo por pasos hubiera elegido $\hat{\gamma}_1 = \hat{\beta}_1$, mientras que el algoritmo por etapas hubiera seguido un camino escalonado a partir de $\hat{\gamma}_1 x_1$ para llegar a $\hat{y}$, mientras de que LARS elige un camino intermedio.

Algoritmo LARS en el caso general

Como vimos antes, para dos vectores, el algoritmo toma la dirección de la bisectriz entre ellos. Podemos generalizar este concepto para más vectores:

Definición 0.0.1 (Vector equiangular). Sean $\{x_1, \dots, x_r\}$ vectores y X la matriz cuyas columnas son dichos vectores. Decimos que un vector u es equiangular a los vectores $\{x_1, \dots, x_r\}$ si

$$X^T u = \begin{bmatrix} \alpha \\ \vdots \\ \alpha \end{bmatrix},$$

para alguna constante α .

Es natural preguntarse cuando podemos encontrar vectores equianguulares, para ello tenemos el siguiente resultado:

Teorema 0.0.1 (Existencia de vectores equianguulares). *Supongamos que $\{x_1, \dots, x_n\}$ son linealmente independientes. Entonces, existe un vector equiangular a dichos vectores que además es unitario.*

Demostración

Sea W la matriz con columnas $\{x_1, \dots, x_r\}$. Notemos que trivialmente se cumple que $W^T W \mathbf{1}_n = \mathbf{1}_n$, de manera que

$$(W^T W)(W^T W)^{-1} \mathbf{1}_n = \mathbf{1}_n.$$

Así, si hacemos $u' = W(W^T W)^{-1} \mathbf{1}_n$, entonces tenemos un múltiplo del vector u buscado. Además, como

$$\begin{aligned} \|u'\|^2 &= \mathbf{1}_n (W^T W)^{-1} W^T W (W^T W)^{-1} \mathbf{1}_n \\ &= \mathbf{1}_n (W^T W)^{-1} \mathbf{1}_n \end{aligned},$$

se tiene que

$$u = \frac{W(W^T W)^{-1} \mathbf{1}_n}{[\mathbf{1}_n (W^T W)^{-1} \mathbf{1}_n]^{\frac{1}{2}}},$$